تحلیل یه صفحه ای Give Me Some Credit

خلاصه

- ویژگی‌های سوابق تاخیر قوی‌ترین سیگنال را دارند، اما با هم همبسته‌اند؛ در مدل خطی فقط یکی از آن‌ها را نگه داریم.
- میانگین و باکس‌پلات به‌خاطر مقادیر پرت گمراه‌کننده‌اند؛ از میانه و نرخ بدهکاری هر گروه استفاده کنیم.
- رابطه سن و Utilization با هدف غیرخطی است و فقط با WOE و MI دیده می‌شود.

1. ویژگی‌های ساخته‌شده: چرا خوب است و چرا نه

ویژگی	نوع	نقطه قوت	نقطه ضعف
TotalPastDue	تجمیعی	• بیشترین اطلاعات متقابل: 0.0492 • میانگین 2.05 برای مشتری بد در برابر 0.28 برای خوب	• شدت تاخیر را نادیده می‌گیرد: 30 روز با 90 روز برابر است • همبستگی 0.82 با تاخیر 30-59
Has90DaysLate	دودویی	• نرخ بدهکاری 41.9% در برابر 4.6% • ساده و منطبق بر تعریف مشتری بد	• تعداد تاخیرها را از دست می‌دهد • همبستگی 0.78 با NumberOfTimes90DaysLate • باید پیش از بازه هدف ثبت شده باشد، وگرنه نشت زمانی است
WorstDelayStatus	شدتی، 0 تا 3	• شدت را در یک متغیر ترتیبی نگه می‌دارد • اطلاعات متقابل 0.0478	• فاصله سطوح را برابر فرض می‌کند؛ برای مدل خطی WOE یا One-Hot بهتر است • همبستگی 0.81 با Has90DaysLate
MonthlyIncome_missing	شاخص گمشدگی	• خود گمشدگی اطلاعات دارد: نرخ بد 6.88% در برابر 5.47% • بعد از پر کردن با میانه، این سیگنال حفظ می‌شود	• اطلاعات متقابل تقریبا صفر: 0.0003 • ممکن است فرایند ثبت داده را بسنجد، نه رفتار مشتری
AgeGroup + WOE	گروه‌بندی	• IV برابر 0.238، یعنی متوسط، با الگوی یکنوا • پایدار و مناسب اسکورکارت	• اطلاعات درون هر گروه از بین می‌رود • اطلاعات متقابل سن فقط 0.0075 است و با IV هم‌خوان نیست

2. تحلیل نمودارها

نمودار	چه می‌بینیم	نتیجه و اقدام
باکس‌پلات تک‌متغیره	• در DebtRatio، Utilization و MonthlyIncome چند مقدار بسیار بزرگ (بیشینه DebtRatio: 220,516) محور را می‌کشد و جعبه به یک خط تبدیل می‌شود • در شمارنده‌ها Q1 = Q3 = 0 است و هر مقدار غیرصفر پرت می‌شود: 51,207 ردیف، یعنی 48.9% آموزش	• پرت بودن آماری یعنی خطا نیست: نرخ بد این ردیف‌ها 10.6% در برابر 6.6% است • حذف نکنیم؛ Winsorize یا Robust Scaling
باکس‌پلات بر حسب هدف	• سن: جعبه‌ها هم‌پوشانی دارند؛ میانگین 46.1 در برابر 52.8 • تاخیرها: جعبه مشتری خوب یک خط صفر است و جعبه مشتری بد بالاتر؛ تفکیک قوی است • Utilization، DebtRatio و درآمد: جعبه‌ها زیر پرت‌ها گم می‌شوند	برای این سه متغیر از میانه یا نرخ بد هر گروه استفاده کنیم
هیت‌مپ همبستگی	• یک خوشه تکراری: سه شمارنده خام و سه ویژگی ساخته‌شده، با همبستگی 0.52 تا 0.82 • بیرون از خوشه، بیشترین همبستگی 0.43 است	• از خوشه یک نماینده انتخاب کنیم (هم‌خطی، VIF بالا) • برای متغیرهای دودویی و دم‌سنگین Spearman دقیق‌تر است
اطلاعات متقابل (MI)	• ترتیب: TotalPastDue با 0.0492، WorstDelayStatus با 0.0478 و Utilization با 0.0370 • Utilization همبستگی خطی تقریبا صفر دارد، $r = -0.002$، ولی رتبه سوم است	• رابطه Utilization غیرخطی است؛ گروه‌بندی یا WOE کنیم • سن با IV برابر 0.238 فقط رتبه هشتم MI را دارد؛ discrete_features را مشخص کنیم

3. ویژگی‌های پیشنهادی و شاخص‌های ارزیابی

ویژگی‌های پیشنهادی

- **نسبتی:** DebtAmount = DebtRatio × MonthlyIncome (برای درآمد گمشده، DebtRatio مقدار مطلق است)؛ درآمد سرانه؛ سهم وام مسکن از کل خطوط
- **دودویی:** Utilization > 1، DebtRatio > 1، HasAnyPastDue، HasMultiplePastDue
- **شدتی:** تاخیر وزنی N90+ + 3·N60-89 + 2·N30-59؛ نسبت N90+ به TotalPastDue
- **تبدیل و تعاملی:** log1p برای Utilization و DebtRatio؛ Utilization × Has90DaysLate
- **زمانی:** زمان از آخرین تاخیر و روند Utilization؛ به تاریخچه ماهانه نیاز دارد و در این داده نبود :(

شاخص‌های دیگر ارزیابی ویژگی

- **تفکیک:** AUC تک‌متغیره، Gini، آماره KS، آزمون Mann-Whitney، Cramér’s V
- **پایداری:** PSI بین آموزش و آزمون؛ مقدار بالاتر از 0.25 یعنی جابه‌جایی جدی
- **افزونگی:** VIF و Spearman
- **مدل‌محور:** Permutation Importance، SHAP، ضرایب Lasso، اهمیت درختی
- **عملی:** نرخ گمشدگی، یکنوایی WOE، تفسیرپذیری و ملاحظات حقوقی SEX